



## ΟΙΚΟΝΟΜΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ ΕΡΓΑΣΙΑ 2 MovieLens Tables

### ΣΤΟ ΜΑΘΗΜΑ ΒΑΣΕΙΣ ΔΕΔΟΜΕΝΩΝ ΔΙΔΑΣΚΩΝ: ΒΑΣΪΛΗΣ ΒΑΣΆΛΟΣ

Μόλις συνδεθήκατε στον ίδιο λογαριασμό στο azure data studio ώστε να δουλεύουμε παράλληλα και να έχουμε πρόσβαση σε όλα τα αρχεία. Φτιάξαμε ένα διάγραμμα στο οποίο αναλύσαμε το κάθε csv αρχείο καθώς και τι περιέχει. Πριν αρχίσουμε να γράφουμε όμως κώδικα SQL φτιάξαμε τον κώδικα της python ο οποίος δέχεται τον φάκελο Keywords και δημιουργεί δύο νέους φακέλους τον keyword και τον haskeyword . Παράλληλα διαχωρίζει τον αρχικό πίνακα και διαγραφεί τα διπλότυπα.

Ο κώδικας της python διαβάζει ένα αρχείο CSV που περιέχει δεδομένα σχετικά με λέξεις-κλειδιά για ταινίες. Κάθε γραμμή του αρχείου αποτελείται από έναν αριθμό ταινίας και μια συμβολοσειρά JSON που περιέχει λέξεις-κλειδιά για τη συγκεκριμένη ταινία. Στη συνέχεια, αναλύει τη συμβολοσειρά JSON για κάθε ταινία και αποθηκεύει τα μοναδικά λέξεις-κλειδιά και τις σχέσεις ταινιών-λέξεων-κλειδιών σε δύο λεξικά. Τέλος, γράφει τα μοναδικά λέξεις-κλειδιά σε ένα αρχείο CSV με το όνομα "Keyword.csv" και τις σχέσεις ταινιών-λέξεων-κλειδιών σε ένα άλλο αρχείο CSV με το όνομα "haskeyword.csv".

Πρώτος σκοπός μας ήταν να μετατρέψουμε τα αρχεία csv σε tables στο azure data studio. Καθώς δημιουργούμε το κάθε table χρησιμοποιούσαμε τον κώδικα ο οποίος δόθηκε από την εκφώνηση ώστε να βάλουμε primary και secondary keys όπου χρειαζόταν και τον τρέχαμε ώστε να βεβαιωθούμε ότι δεν υπάρχει κάποιο error. Πιο συγκεκριμένα οι περιορισμοί πρωτεύοντος κλειδιού (Primary Key) σε κάθε πίνακα διασφαλίζουν ότι η στήλη ή οι στήλες που ορίζονται ως πρωτεύον κλειδί είναι μοναδικές. Οι πίνακες που επηρεάζονται είναι οι movie, genre, productioncompany, collection, movie\_cast, movie\_crew, Keyword, ratings και hasKeyword. Στα ξένα κλειδιά οι περιορισμοί δηλώνουν ότι οι σχέσεις μεταξύ των πινάκων, όπου η τιμή μιας στήλης στον έναν πίνακα αναφέρεται ως "ξένο κλειδί" σε μια στήλη σε έναν άλλο πίνακα. Οι πίνακες που επηρεάζονται είναι οι movie\_cast, movie\_crew, ratings, belongsTocollection, hasGenre, hasProductioncompany, και hasKeyword.

Συνολικά, ο κώδικας αυτός διασφαλίζει ότι οι πίνακες στη βάση δεδομένων είναι σωστά δομημένοι με πρωτεύοντα και ξένα κλειδιά που τους ενώνουν και εξασφαλίζουν τη συνοχή των δεδομένων.